

추천시스템 MovieLens

20230861 박지연, 20230863 박한비, 20231350 노은서



역할 분담

아이템 기반 이웃CF

노은서

- MovieLens 100K는 평점 행렬이 희소하기 때문에, 사용자 간 공통 평가 부족 문제를 줄이고 타겟 사용자의 기존 평점을 활용할 수 있는 아이템 기반 이웃 CF를 선택함
- 장점: 추천 결과가 일부 인기 영화에만 집중되지 않고 다양한 영화로 확장됨
- 단점: 평점 수가 적은 영화가 추천목록에 포함되어 카탈로그 커버리지가 과도하게 높게 나타남
- 해결방안: min_count=30 기준을 검토하여 평점 데이터 부족 영화의 영향을 확인함

모델 기반 이웃CF

박지연

- 사용자-아이템 평점 행렬의 희소성 문제를 해결하고 명시적 평점 너머의 잠재적 선호 패턴을 학습하기 위해 행렬 분해(Matrix Factorization) 기반 모델을 선택
- 장점: 전체 평점 행렬을 학습에 활용하여 직접 평점을 남기지 않은 아이템에 대해서도 평가 가능
- 단점: 평점이 많은 인기 아이템일수록 잠재요인이 정확히 학습되어 추천이 인기 아이템에 집중됨
- 해결방안: 추천 빈도에 따른 log penalty 적용해 인기가 없는 아이템도 추천할 수 있도록 설계함

앙상블

박한비

- 최적의 단일 모델을 선정하기 위해 이웃 기반 CF와 모델 기반 CF를 구현하고 서로 다른 특성을 가진 두 모델을 3가지의 방식으로 결합함
- 장점 : 아이템 기반의 지역적 유사성과 모델 기반의 잠재요인 정보의 결합으로 높은 예측 정확도와 동시에 추천 다양성을 유지함
- 단점: 커버리지 측면에서, 잠재요인 기반 추천의 영향으로 일부 인기 아이템 집중 현상이 남아있음
- 해결 방안 : 인기도를 기반으로 롱테일 아이템에 추가 가중치를 부여하는 Long-tail Weighted Ensemble을 설계

아이템 기반 이웃 CF

구현 설정

- **사용자 평균 중심화**
사용자마다 평점을 후하게/박하게 주는 차이를 줄이기 위해, 각 사용자의 평균 평점을 기준으로 평점을 보정함.
- **아이템 간 코사인 유사도 계산**
- **예측 불가 상황에 대한 평균 기반 fallback**
유사 아이템이 부족하거나 예측값을 계산할 수 없는 경우, 전체 평점 평균·사용자 평균 평점·영화 평균 평점을 활용해 대체 예측값을 생성함
- **k값 별 validation 성능 비교 후 최종 k=30 선택**
유사 영화 개수 k를 10, 20, 30으로 비교하고, validation 성능이 가장 안정적인 k=30을 사용함

k	RMSE	MAE
10	0.9408	0.7339
20	0.9306	0.7279
30	0.9302	0.7292
40	0.9312	0.7311 ₃

큰 예측 오차에 더 민감한 RMSE를 주요 기준으로 하여,
RMSE가 가장 낮은 K=30을 최종 선택함

아이템 기반 이웃 CF

평가 메트릭 별 구현 난이도

- **RMSE/MAE**

- 사용자별 평가 이력과 아이템 유사도 행렬을 매칭하여 예측 평점을 계산함
- user_id와 movie_id가 1부터 시작해 0행0열이 평가에 포함되지 않도록 인덱스를 정리함

- **Kendall Tau**

- 사용자별 test 영화를 다시 묶어 실제 평점 순위와 예측 평점 순위를 비교함
- 비교 가능한 영화가 2개 미만이거나, 실제 평점 순위/ 예측 평점이 모두 동일해 순위 비교가 어려운 사용자는 제외함

- **Catalog Coverage**

- 본 실험에서 Coverage@10/20/30의 결과값이 0.7~0.9 수준으로 매우 높게 나타남
- 추천 목록을 확인한 결과, 평점 수가 매우 적은 롱테일 영화도 상위권에 포함됨을 확인함
- min_count=30 조건을 적용해서 평점 근거가 부족한 영화의 영향을 검토함

- **다양성**

- u.item의 장르 벡터와 추천 결과를 연결함
- 사용자별 추천 리스트 내부 영화 쌍의 장르 코사인 유사도를 평균내어 다양성을 계산함

모델 기반 CF 선택 모델

- 기본적인 모델 기반 추천시스템 제작 후 RMSE가 낮은 모델 선택

	RMSE	MAE	KendallTau
Model			
Baseline Bias	0.935615	0.738787	0.419915
Item-based CF	0.916159	0.723336	0.443032
Item-based Implicit CF	0.933845	0.739082	0.421774
Latent Factor / Matrix Factorization	0.935650	0.739415	0.420105
Hybrid model	0.915291	0.720757	0.443545

- RSME 기준, 가장 좋은 Hybrid model 평가 지표

Model	RMSE	MAE	KendallTau
Hybrid model	0.9513	0.748787	0.403216

Model	CC@10	CC'@10	CC@20	CC'@20	CC@30	CC'@30
Hybrid model	0.109489	0.15843	0.155718	0.235465	0.182482	0.280523

Model	Div@10	Div@20	Div@30
Hybrid model	0.792536	0.693444	0.753193

모델 기반 CF 선택 모델

- 구현 난이도

1. 정확도 측면

행렬 분해시 feature K 임의로 설정



Feature K 개수에 따른 정확도 평가

MF_factor_K	val_RMSE	val_MAE	val_KendallTau
10	0.915285	0.720897	0.443427
50	0.915291	0.720757	0.443545
30	0.915340	0.721065	0.443452
20	0.915344	0.720850	0.443529
100	0.915657	0.721109	0.443123
80	0.915801	0.721192	0.443125

선택 기준 : RSME가 가장 낮은 k

2. 커버리지, 다양성 측면

이웃기반, 앙상블에 비해 낮은 커버리지, 다양성



인기 많은 아이템에 편향됨



추천 빈도에 따른 Log penalty주는 모델 생성

BaseModel	beta	RMSE	MAE	KendallTau	MeanCC	MeanDiv
Best 5-model (Hybrid model)	0.05	0.917407	0.726683	0.441986	0.238753	0.725228
Best 5-model (Hybrid model)	0.10	0.925000	0.737526	0.434902	0.312751	0.689050
Best 5-model (Hybrid model)	0.20	0.956218	0.769598	0.399210	0.290202	0.644382
Best 5-model (Hybrid model)	0.40	1.074505	0.859323	0.292408	0.216588	0.653903
Best 5-model (Hybrid model)	0.80	1.382564	1.057900	0.151869	0.187560	0.654297
Best MF factor K (K=10)	0.05	0.917423	0.726965	0.441869	0.239158	0.719094
Best MF factor K (K=10)	0.10	0.924994	0.737818	0.434850	0.305557	0.698182
Best MF factor K (K=10)	0.20	0.956025	0.769778	0.399602	0.286321	0.665425
Best MF factor K (K=10)	0.40	1.073508	0.859140	0.293521	0.220931	0.668331
Best MF factor K (K=10)	0.80	1.379537	1.056407	0.152164	0.181651	0.668908

선택 기준 : RSME가 0.95 이하이며 커버리지와 다양성을 가장 높이는 beta

- 최종 선택 모델 : mf factor k=10 & beta = 0.1 인 Hybrid model

앙상블

1. 앙상블 할 모델을 구현하고 RMSE 값을 기준으로 선택

- 아이템 기반 CF의 RMSE

	model	RMSE	
0	Basic Item-CF	1.010580	: null 값을 0 으로 채운 item-CF
1	Mean-Centered Item-CF	0.947380	: mean centering 하여 계산한 item-CF
2	Mean-Centered Item-CF Top-30	0.930488	: mean centering 후 top-k 를 제한하여 구한 item-CF

→ 가장 성능이 좋은 Mean-Centered Item-CF top-30 을 선택 : A 모델

- 모델 기반 CF의 RMSE

	Model	RMSE	
0	Manual Integrated Hybrid	0.915538	: Baseline Bias + implicit feedback + Item-Item Neighborhood
1	Manual SVD++	0.932527	: basic SVD + implicit feedback
2	Manual Basic SVD	0.932682	: basic SVD 모델

→ 가장 성능이 좋은 Manual Integrated Hybrid 를 선택 : B 모델

앙상블

1. **weighted hybrids** ← 최종 모델로 선택

- A 모델과 B 모델을 가중치 α 를 0부터 1.0까지 0.05 씩 증가 시켜 최적의 α 를 찾아 결합한다
- $$\hat{r} = \alpha \hat{r}_{ItemCF} + (1 - \alpha) \hat{r}_{Hybrid}$$

Best alpha for Item-CF: 0.350000000000000003
Best alpha for Integrated Hybrid: 0.649999999999999999

← 정확도가 높은 Hybrid 모델을 중심으로 Item-CF의 이웃 정보를 일부 반영

2. Bagging

- B 모델에 대해 여러 개의 모델을 학습 데이터의 다른 부트스트랩 샘플으로 학습시킨 후, 이 모델들의 예측을 종합하여 최종 예측을 만든다

3. Boosting-style Sequential Ensemble

- 예측 오차가 큰 데이터의 가중치를 증가시켜 학습한다

	Rank	Model	RMSE	MAE	Coverage@10	Coverage@20	Coverage@30	Filtered Coverage@10	Filtered Coverage@20	Filtered Coverage@30	ILD@10	ILD@20	ILD@30
0	1	Weighted Ensemble	0.9423	0.7447	0.3282	0.4227	0.4768	0.4627	0.5450	0.5887	0.7219	0.7252	0.7298
1	2	Manual Integrated Hybrid	0.9490	0.7522	0.1855	0.2206	0.2491	0.3882	0.4550	0.5103	0.7314	0.7259	0.7258
2	3	Integrated Boosting	0.9544	0.7651	0.1635	0.2122	0.2354	0.3483	0.4434	0.4846	0.7430	0.7427	0.7392
3	4	Integrated Bagging	0.9718	0.7714	0.0761	0.1183	0.1427	0.1620	0.2519	0.3021	0.7044	0.7127	0.7228

<평가 metric 비교>

앙상블

낮은 카탈로그 커버리지 값 개선

- 영화 인기를 기반으로 **롱테일 아이템**에 **추가 가중치**를 부여하는 long-tail weighted ensemble 설계
- 롱테일 가중치 λ 증가에 따라 Coverage가 최대 약 **5.8%** 증가, RMSE는 약 **1.7%** 악화
→ 적은 정확도 손실로 더 다양한 영화가 추천 가능함이 시사됨

	lambda	RMSE	MAE	Coverage@10	Coverage@20
0	0.00	0.941903	0.745354	0.328181	0.422711
1	0.02	0.942522	0.744976	0.331153	0.422117
2	0.05	0.943846	0.744675	0.334126	0.427467
3	0.10	0.947106	0.744952	0.343044	0.436980
4	0.15	0.951663	0.746265	0.343639	0.442925
5	0.20	0.957500	0.748471	0.347206	0.447087
6	0.30	0.972900	0.755737	0.350773	0.450654
7	0.50	1.017577	0.782160	0.361474	0.448276

증가

<가중치에 따른 RMSE, MAE 와 catalog coverage 값 비교>

비교 분석 - 1. 정확성

	평점 예측 정확도	
	RMSE	MAE
아이템 기반 이웃 CF	0.9559	0.7468
모델 기반 CF (MF factor K + Debaised)	0.9580	0.7644
앙상블 (weighted hybrids)	0.9423	0.7447

순위 평가 정확도
Kendall Tau
0.2965
0.3961
0.3177

- 평점 예측 정확도: 앙상블>이웃기반CF>모델기반CF
 - 앙상블의 강점 : 예측값의 가중 결합으로 단일 모델의 극단적인 오차를 상쇄하여 절대 점수 예측의 안전성을 확보함
- 순위 평가 정확도 : 모델기반CF>앙상블>이웃기반CF
 - 모델 기반 CF의 강점: 편향 제거와 잠재요인 추출을 통해, 절대 점수보다는 아이템 간의 상대적 선호도를 가리는데 탁월함
 - 이웃CF의 한계 : 전체적인 아이템을 훑어보지 못하고, 유사한 특정 아이템들 사이에서만 추천을 시도함

=> 평점 예측 정확도는 앙상블이 우수했지만, 실제 추천 목록의 순위 평가에서는 모델 기반CF가 더 강점을 보임

비교 분석 - 2. Catalog Coverage

1. 일반 카탈로그 커버리지

2. 평점 수가 너무 적은 영화들을 제외하여 (min count = 30) 계산한 카탈로그 커버리지

	CC@10	CC@20	CC@30	CC30@10	CC30@20	CC30@30
아이템 기반 이웃 CF	0.7461	0.9173	0.9643	0.4476	0.4625	0.4625
모델 기반	0.1740	0.2348	0.2603	0.3183	0.4055	0.4404
weighted hybrids	0.3282	0.4227	0.4768	0.4627	0.5450	0.5887

- 이웃 기반

- latent factor를 학습하는 다른 모델과 달리 평가 수가 작은 아이템 추천을 많이 함 → 일반 커버리지 가장 높음
- 하지만, 0.9643은 거의 1에 가까운 수치로 무작위 추천과 유사해짐
- Min-count 30 이후 커버리지 낮아짐 → 희소 아이템 추천해주는 장점 감소 & 무작위 가능성 감소

- 모델 기반

- latent factor를 학습하며 예측 안정성이 높은 인기 아이템에 추천이 몰림
- min-count 30 이후 희소 아이템의 latent factor 예측 불안정성 제거 → 더 높은 커버리지를 가짐

- 앙상블

- 이웃 기반의 큰 커버리지, 모델 기반의 예측력이 결합 돼 극단적으로 치우치지 않음
- 특히 **Min-count 30** 커버리지에서 희소 아이템 노이즈가 제거되며 가장 좋은 성능을 보임

→ 일반 커버리지는 이웃 기반이 높았지만, 과대평가 가능성이 있음

→ Min-count 30 적용 후 앙상블이 가장 높아, 신뢰도 있는 아이템 범위에서는 앙상블의 커버리지 안정성이 우수함

비교 분석 - 3. 장르 다양성

- 다양한 장르의 영화를 추천하는지 u.item 정보를 이용하여 비율로 0-1 값으로 표현

	diversity@10	diversity@20	diversity@30
아이템 기반 이웃 CF	0.7280	0.7286	0.7308
모델 기반	0.6699	0.7076	0.7169
weighted hybrids	0.7219	0.7252	0.7298

- 이웃 기반 CF가 가장 높은 다양성을 보임
 - 특정 잠재 요인에 집중하기보다는 **다양한 장르**의 영화가 추천 목록에 포함될 가능성이 높아 상대적으로 높은 다양성을 보임
- 모델 기반이 가장 낮은 다양성을 보임
 - 사용자가 선호할 가능성이 높은 영화에 집중하게 되므로 추천 목록이 특정 장르나 특성에 **편중**될 수 있음
- 앙상블 모델은 정확도와 다양성의 균형을 달성함
 - 이웃 기반 CF + 모델 기반의 최적 가중치로 결합하여 성능 균형을 달성함

→ 추천 정확도와 장르의 다양성 사이의 **Trade-off** 현상이 나타남

